

3 数据特征的描述

3.1 总量指标和相对指标


3.2 统计数据集中趋势的描述—平均指标

3.3 统计数据离中趋势的描述—变异指标

3.4 数据分布形态的描述—偏度和峰度

3.5 Z-分数与相关定理

3.6 箱线图



3.1 总量指标和相对指标

3.1.1 总量指标

3.1.2 相对指标

总量指标（例——摘自国家统计局统计公报2024.2.29）

- (2023) 全年国内生产总值1260582亿元，比上年增长5.2%。
- 年末全国人口140967万人，比上年末减少208万人。全年出生人口902万人，死亡人口1110万人。
- 年末国家外汇储备32380亿美元。全年货物进出口总额417568亿元，比上年增长0.2%。
- 全年全国一般公共预算收入216784亿元。
- 年末广义货币供应量（M2）余额292.3万亿元。年末全部金融机构本外币各项存款余额289.9万亿元
- 全年货物运输总量557亿吨。货物运输周转量247713亿吨公里。全年旅客运输总量93亿人次，比上年增长66.5%。旅客运输周转量28610亿人公里，增长121.4%。
- 全年一次能源生产总量48.3亿吨标准煤，比上年增长4.2%。

3.1.1 总量指标

1.总量指标的概念、作用

总量指标——也称为统计绝对数

- 表明现象总规模或绝对水平
- 绝对数的形式表示
- 一般通过计数、测量和汇总得到

总量指标的作用

- 是认识社会经济现象的起点；
- 是进行管理的重要依据；
- 是计算相对指标、平均指标的基础。

2. 总量指标的计量单位

实物单位



实物量指标

● 以事物的自然属性和特点进行计量的单位，包括：

- 自然单位：如人、只、台、件...，是长期习惯使用形成，用于离散型数据。
- 度量衡单位： kg、cm、...，用于连续型数据。
- 标准实物单位：按某一标准（含量、规格、功效等）折算后的实物单位，用于将用途相同、但规格或含量不同的物品数量汇总。如粮食、能源（标准吨）等；
 标准实物量指标（折合量）
- 复合单位： 吨公里、人公里、人次数、工日...

实物单位（续）

- 特点

- 使用价值明确；
- 综合性能差，不同使用价值的实物量不能直接汇总。

- 用途

- 反映重要物资的生产和消耗、主要产品的供需平衡、特别是无法估价的土地面积和自然资源数量等。

2. 总量指标的计量单位（续）

价值单位（货币单位） → 价值量指标

- 如人民币元，对外贸易中使用英镑、美元、欧元等。
- 特点：
 - 具有较强的综合性和概括能力，
 - 内容抽象，而且要受价格波动的影响。
- 用途：表明经济活动的总成果、总规模，广泛用于经济效益的考核和评价等。

3. 总量指标的种类

1、按反映总体的特征（内容）分为：

● 总体总量

- 即总体单位总数
- 表示总体本身的规模大小

● 标志总量

- 即总体各单位某一数量标志值总和。
- 表示所研究现象的总水平。

● 总体单位总量与标志总量的区分，不是固定不变的，而是随着研究目的和研究对象的不同而变化的。

- 如：某地区工业企业职工总数100万人，这是一个：
 - 总体总量——以该地区每个工业企业职工为总体单位时
 - 标志总量——以该地区每个工业企业为总体单位时

3. 总量指标的种类（续）

按反映的时间状况分

- 时期指标——也称为流量
 - 反映总体在一段时期内活动过程的总量，
 - 指标数值可以累计相加，
 - 数值大小和时间的长短有直接关系；
- 时点指标——也称为存量
 - 是反映总体在某一时刻（瞬间）状况的总量
 - 数值不能累计相加，
 - 数值的大小和时间间隔的长短没有直接关系。
- 试判断下列指标中哪些是时期指标？
 - 人口总数、在校学生人数、招生人数、毕业生人数、出生人数、死亡人数、从业人数、失业人数

经济流量与经济存量之间的关系

- 存量是以前流量的积累，而存量的变动(增减)又是流量的一种表现形式。
- 有的流量有对应的存量（如产品产量与存货）；有的流量（如出口量）没有对应的存量。
- 流量与存量之间有如下的平衡关系：

$$\text{期末存量} = \text{期初存量} + (\text{本期增加的流量} - \text{本期减少的流量})$$

如：期末资产 = 期初资产 + 本期增加的资产 - 本期减少的资产

期末存款余额 = 期初存款余额 + 本期增加的存款 - 本期减少的存款

4. 国民经济中的重要总量指标

● **总产出**（物质生产部门也叫总产值）——常住单位在一定时期内生产的全部货物和服务的价值，包括中间投入的转移价值和最终成果的价值。 **总产出 = $c + v + m$**

● **(1) 国内生产总值**（**Gross Domestic Product**，缩写为**GDP**），是按市场价格计算的一个国家所有常住单位在一定时期内生产活动的最终成果。 **$GDP = c' + v + m$**

- 生产法：国内生产总值 = Σ （增加值）
 $= \Sigma$ （总产出 - 中间投入 c'' ）
- 收入法：国内生产总值 = 固定资本折旧（ c' ） + 劳动者报酬（ v ） + 生产税净额 + 营业盈余
- 支出法：国内生产总值 = 最终消费（即总消费） + 资本形成总额（即总投资） + 净出口

国民经济中的重要总量指标(1)

GDP的平衡原则——理论上，三种方法计算结果相等。实际上总有误差。我国以生产法结果为准，把误差放在支出方。

国内生产总值表基本结构

生 产	金 额	使 用	金 额
一、生产法国内生产总值		一、支出法国内生产总值	
(一) 总产出		(一) 最终消费	
(二) 中间投入 (一)		居民消费	
二、收入法国内生产总值		农村居民消费	
(一) 劳动者报酬		城镇居民消费	
(二) 生产税净额		政府消费	
生产税		(二) 资本形成总额	
生产补贴 (一)		固定资本形成总额	
(三) 固定资产折旧		存货增加	
(四) 营业盈余		(三) 净出口	
		出口	
		进口 (一)	
		二、统计误差	

国民经济中的重要总量指标(1)

GDP三种方法有关总量的派生指标:

生产法: 国内生产总值 = Σ (增加值) = Σ (总产出 - 中间投入 c'')

——计算经济效益指标: 中间投入(消耗)率 (= 中间投入/总产出)
增加值率 (= 增加值/总产出) } 二者之和=1

收入法: 国内生产总值 = 固定资本折旧 (c') + 劳动者报酬 (v) + 生产税净额 + 营业盈余

——可计算国家所得、企业所得、劳动者个人所得三者的占比, 反映初次分配的比例关系

支出法: 国内生产总值 = 最终消费 (即总消费) + 资本形成总额 (即总投资) + 净出口

——可计算消费率、投资率、净出口率, 分析三驾马车对经济增长的贡献

【例】



指标 ◆	2022年 ◆
最终消费支出对国内生产总值增长贡献率(%)	32.8
最终消费支出对国内生产总值增长拉动(百分点)	1.0
资本形成总额对国内生产总值增长贡献率(%)	50.1
资本形成总额对国内生产总值增长拉动(百分点)	1.5
货物和服务净出口对国内生产总值增长贡献率(%)	17.1
货物和服务净出口对国内生产总值增长拉动(百分点)	0.5

国民经济中的重要总量指标(续2)

(2) 国民总收入 (*GNI*)

- 原名：国民生产总值 (*GNP*)
- 一国常住单位因为投入生产要素（劳动力、土地、资本）而获得的初次分配总收入。
- 国民总收入 = 国内生产总值 + 来自国外的要素收入净额

(3) 国民可支配总收入。

- 在初次分配总收入的基础上，一国常住单位与非常住单位之间通过经常转移的形式对初次分配总收入进行再次分配而获得的总收入。
- 国民可支配总收入 = 国民总收入 + 来自国外的经常转移收入净额

国内生产总值与有关指标的关系



注：国民总收入GNI=以前的“国民生产总值（GNP）”

Net, National, Disposable

对比分析法

- 最简单的但也是应用最广泛的统计分析方法。
- 可以采用相减的方法，
- 也可以采用相除的方法—— 计算相对数。
 - 实际应用中通常所说的对比分析是通过计算相对数来进行的。

3.1.2 相对指标

1. 相对指标的意义

概念

$$\text{相对指标} = \frac{\text{某一统计数值}}{\text{另一有联系的统计数值}}$$

- 两个有联系的指标对比的比率
- 有两种表现形式
 - 无名数
 - 百分比(%)、千分比(‰)、倍数、系数、成数、番数等
 - 名数——分子与分母的计量单位构成的复名数

关于百分比的变动



贷款利率从 **5%** 上升至 **6 %**，贷款利率上升了 ? %

➤ 上升了 **1** % ?

➤ 上升了 **20 %**，上升了 **1** 个百分点

百分比与百分点、千分比与千分点

- **百分比 (%)** —— 两个数相除的结果的表现形式，将对比的基数（分母）化为100；
- **百分点** —— 两个百分比之差的表现形式。
- **千分比 (‰)** —— 两个数相除的结果的表现形式，将对比的基数（分母）化为1000；
- **千分点** —— 两个千分比之差。
- **基点**

谁是亚洲最赚钱的公司？

——用哪个指标来对比？

中国石油上市时——

	总股本 (万股)	盈利总额 (亿元)	每股收益 (元)	净资产 收益率 (%)	经营 净利率 (%)	经营 毛利率 (%)
中国石化	8670244	549.43336	0.6337	18.26	4.5605	13.0787
中国石油	18302098	1345.75325	0.7353	19.90	16.1159	33.4413
贵州茅台	94380	28.3083372	2.9994	34.38	39.1138	79.6099



相对指标的意义

- 相对数可以反映现象之间或现象内部的数量对比关系。
- 相对数可以使一些不能直接对比的现象能够进行比较。
- 相对数是进行宏观调控和企业经营管理的重要工具。国民经济中有许多重要的比率关系，如速度、比例、效益等，都要通过相对数来进行分析；一个企业生产质量的高低、经济效益的高低也要用许多相对数来反映。

2. 相对指标的种类及作用

(1) 结构相对数（比重）

$$\text{结构相对数} = \frac{\text{总体中某一部分的数值}}{\text{总体的数值}} \times 100\%$$

- 反映社会经济现象的内部结构以及分布状况。
- 各组比重之总和=100%

如：市场占有率；人口城镇化率；恩格尔系数

2023年全国居民恩格尔系数为29.8%，其中城镇为28.8%，农村为32.4%。



(2) 比例相对数——比例（结构性的比例）

$$\text{比例相对数} = \frac{\text{总体中某一部分的数值}}{\text{总体中另一部分的数值}} \times 100\%$$

反映总体内部的比例关系，揭示总体不同部分之间的发展变化的协调平衡状况。

如：2023年国内生产总值1260582亿元，一二三产业增加值的比例为 1:5.39:7.69 或 7.1%：38.3%：54.6%。

消费与积累（投资）的比例

某地区农轻重比例

两种商品价格之比——比价

• 分子分母可互换

(3) 比较相对数

$$\text{比较相对数} = \frac{\text{甲空间某类现象的数值}}{\text{乙空间同类现象的数值}} \times 100\%$$

- 相同时间不同空间同类现象数值的对比，
- 说明不同空间的经济势力强弱和工作优劣等。
- 分子分母可互换。

如前面的企业之间的比较

(6) 动态相对数

$$\text{动态相对数} = \frac{\text{报告期水平}}{\text{基期水平}} \times 100\%$$

基期：充当比较基准的时间；

报告期：所要说明其变化的时间

- 反映现象发展变化的相对程度（即**发展速度**）。
- $\text{发展速度} - 100\% = \text{增长速度}$

(4) 计划完成相对数

(也称为计划完成百分比)

计划完成相对数

$$= \frac{\text{实际完成数}}{\text{计划任务数}} \times 100\%$$

- 反映计划任务的完成程度。
- 应以计划数为比较标准，所以分子和分母不能互换。

例1

某地上年国内生产总值为500亿元，计划为550亿元，实际为560亿元。该地计划完成程度如何？

$$\text{计划完成百分比} = \frac{560}{550} = 101.8\%$$

101.8%的经济意义：超额完成计划 1.8%

【思考1】 若已知今年计划国内生产总值比上年增长10%，实际增长12%，又该如何计算？

【思考1—】解

某地上年国内生产总值为500亿元，今年计划国内生产总值比上年增长10%，实际增长12%。

$$\begin{aligned}\text{计划完成百分比} &= \frac{500 \times (1 + 12\%)}{500 \times (1 + 10\%)} = \frac{560}{550} = 101.8\% \\ &= \frac{1 + 12\%}{1 + 10\%} \times 100\%\end{aligned}$$

【思考2——如何计算计划完成百分比？】

怎样计算超额完成计划百分比？

某企业计划把单位成本降低 3%，实际降低2%。该企业单位成本的计划完成百分比是多少？该企业是否完成了单位成本的计划任务？

【思考2——如何计算计划完成百分比？】

某企业计划把单位成本降低 3%，实际降低2%。如何计算计划完成百分比？该企业是否完成了单位成本降低计划？

$$\text{计划完成百分比} = \frac{1 - 2\%}{1 - 3\%} = 101.03\%$$

$$\text{计划完成百分比} = \frac{1 \pm \text{实际增（减）率}}{1 \pm \text{计划增（减）率}} \times 100\%$$

怎样计算超额完成计划百分比？

在分析计划完成情况时，要注意所考察指标的
性质差异。

- 若是正指标，如产值、利润等，其计划完成相对数大于100%表示超额完成了计划。

超额完成计划百分比=计划完成相对数-100%

- 若是逆指标，如产品成本、原材料消耗量等其计划完成相对数低于100%才超额完成计划。

超额完成计划百分比=100%-计划完成相对数

中长期计划的完成程度

分析长期计划(如五年、十年计划)的 **完成程度**，有两种方法：

累计法——计划任务是规定全期应完成的总量，则用整个计划期实际完成的累计数和计划规定的累计数对比来计算计划完成相对数。

水平法——计划任务是规定计划期末应达到的水平，则实际完成数和计划任务数都是整个计划**期末**（或**最一年**）的水平。

➤ **提前完成计划时间**——连续一年时间（可跨自然年度）达到计划目标，剩余时间即是(见练习题)

计划执行进度

监督计划执行进度时，分子是计划期内某一段时间的实际完成数，分母是全期计划任务数：

$$\text{计划执行进度} = \frac{\text{计划执行之日起至检查之日止实际完成累计数}}{\text{全期计划任务数}} \times 100\%$$

有关**13**亿的大小

● **13**亿，是一个很大的数字，

- 如果你用乘法来算，一个很小的问题，乘以**13**亿，就会变成一个大问题；如果如果你用除法来算，一个很大的总量，除以**13**亿，就会变成一个小数目。这是许多外国人不容易理解的。

——温家宝总理接受《华盛顿邮报》总编采访时说

- 我国铁路货运量、客运周转量居世界第一。2021年底，全国铁路营业里程达到15.7万公里，人均铁路营业里程**11.1厘米**——不及一支普通香烟的长度（**12厘米**）。

(5) 强度相对数

$$\text{强度相对数} = \frac{\text{某一现象的数值}}{\text{另一有联系现象的数值}}$$

- 反映现象的强度，如：人均**GDP**、人均粮食产量...
- 反映现象的密度和普遍程度。如：人口密度、每万人拥有医院数(病床数、医生数)、2023年移动电话普及率**122.5部/百人**。
- 反映经济效益，如资金利润率、投资效果系数。
- 其它，如： 外贸依存度=对外贸易总额/**GDP**
 - 保险密度=保费/人口数, 金融相关率=金融资产总量/**GNP**
 - 能源消耗的弹性系数=能源消耗的增长率/**GDP**增长率
 - 研究与试验发展 (**R&D**) 经费投入强度：R&D经费支出/销售收入 (或GDP)，我国**2023年R&D**经费支出**33278**亿元，比上年增长**8.1%**，与国内生产总值之比为**2.64%**。

强度相对数的特点

- 强度相对数是惟一有单位（且为复名数）的相对数（有的也用无名数形式）；
- 分子分母一般可以互换
 - 故有正指标与逆指标之分。
- 强度相对数常带有“平均”字样，但不是平均数（含义不同）。

相对指标的种类小结

根据研究的目的不同、对比的基础不同，分为：

- 👉 **结构相对数**——反映现象的结构和分布
- 👉 **比例相对数**——反映现象内部比例关系
- 👉 **比较相对数**——评价不同单位的实力、优劣
- 👉 **动态相对数**——反映现象发展变化的状态
- 👉 **计划完成相对数**——检查计划完成程度
- 👉 **强度相对数**——反映现象强度、密度和普遍程度

(三) 计算和应用相对指标应注意的问题

- 正确选择比较基础
 - 如失业率、就业率的计算
- 确保分子分母的可比性
 - 指标内容、口径范围、计算方法、时间等
- 相对数与绝对数结合运用
 - 产品合格率若能达到**99.99%**是非常高了，但阿波罗宇宙飞船上零件达五千六百万个，**0.001%**【十万分之一】的不合格意味着什么？
- 多种相对数综合运用
 - 一个相对指标只能说明一个方面的联系或对比关系

3.2 数据集中趋势的描述

——平均指标


3.2.1 数值平均数

3.3.2 位置平均数

3.3.3 计算和应用平均指标应注意的问题

集中趋势(Central tendency)

- 集中趋势——一组数据向其中心值靠拢的倾向和态势；
- 测度集中趋势就是寻找数据一般水平的代表值或中心值——平均指标。



平均数的种类

按计算方法分：

- **数值平均数**——根据全部数值计算得到的代表值；
 - 算术平均数
 - 调和平均数
 - 几何平均数
- **位置平均数**——根据数据所处位置直接观察或根据与所处位置有关的部分数据计算确定的代表值。
 - 中位数
 - 众数

1、算术平均数（均值）

基本公式：

$$\text{算术平均数} = \frac{\text{总体标志总量}}{\text{总体单位总量}}$$

例： 平均工资=工资总额÷职工人数

平均成本=总成本÷产量

- 均值削弱了个体数值的差异，从整体上揭示了偶然性中的必然性；
- 均值具有唯一性；
- 具有良好的数学性质，是统计推断的重要指标。

【附】算术平均数与强度相对指标的区别

?

____分子与分母的对应关系，例：

$$\text{人均粮食产量} = \frac{\text{粮食总产量}}{\text{人口总数}}$$

$$\text{人均粮食消费量} = \frac{\text{粮食消费总量}}{\text{人口总数}}$$

$$\text{人均GDP} = \frac{\text{国内生产总值 (GDP)}}{\text{人口总数}}$$

$$\text{劳动生产率} = \frac{\text{国内生产总值}}{\text{劳动者人数}}$$

(1) 简单算术平均数——未分组时

5名学生的考试成绩分别为（分）：

70、80、80、85、85，

他们的平均成绩是多少？

$$(70+80+80+85+85) / 5 = 80 \text{ (分)}$$

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{\sum x}{n}$$

(2) 加权算术平均数

——当数据已分组，形成了变量数列：

成绩 x	人数 f
70	1
80	2
85	2
合计	5

$$\text{平均成绩} = (70 + 80 + 85) / 3 \quad ?$$

平均成绩

= 所有人的成绩总和 / 总人数

$$= (70 \times 1 + 80 \times 2 + 85 \times 2) / 5 = 80$$

$$\bar{x} = \frac{x_1 f_1 + x_2 f_2 + \dots + x_n f_n}{f_1 + f_2 + \dots + f_n} = \frac{\sum x f}{\sum f}$$

权数（权重）

● 权数（权重）

- 权衡影响作用的轻重大小的数（变量）；
- 由变量数列计算平均数时，**变量值出现的次数或比重就是权数。**

● 权数的两种形式：

——绝对数（频数**f**）

——相对数（比重**w**）

$$\bar{x} = \frac{\sum xf}{\sum f}$$

$$= x_1 \frac{f_1}{\sum f} + \dots + x_n \frac{f_n}{\sum f} = \sum x \frac{f}{\sum f} = \sum xw$$

● 简单算术平均法是加权算术平均法的特例

【例3-1】

表3-1

工人日产量 (件) x	工人人数 (人) f	工人人数比重 (%) w
10	70	8.75
11	150	12.50
12	380	47.50
13	150	18.75
14	100	12.50
合 计	800	100.00

【例3-1】解

$$\bar{x} = \frac{\text{总产量}}{\text{总人数}} = \frac{\sum xf}{\sum f} = \frac{9710}{800} = 12.1375 \text{ (件)}$$

或 $\bar{x} = \sum xw$

$$\begin{aligned}\bar{x} &= \sum x \frac{f}{\sum f} = 10 \times 0.875 + 11 \times 0.125 + 12 \times 0.475 \\ &\quad + 13 \times 0.185 + 14 \times 0.125 = 12.1375 \text{ (件)}\end{aligned}$$

比重权数更能够直接体现权数的实质

成绩 x	人数		
	f_A	f_B	f_C
70	1	10	10
80	2	20	40
85	2	20	50
合计	5	50	100

不同权数加权的平均数之间有何差异？

怎样由组距数列计算总平均数？

【例3-2】

按成绩分组（分）	学生人数（人）
60以下	2
60—70	15
70—80	20
80—90	15
90—100	4
合计	56

根据组距数列计算总平均数的方法

——加权算术平均法

- x ——各组的组中值（代表组平均水平）
- 假定条件：组内均匀分布或对称分布
- 一般地，计算结果是近似值。

例3-2 的计算结果：

$$\bar{x} = \frac{\sum xf}{\sum f} = \frac{55 \times 2 + 65 \times 15 + 75 \times 20 + 85 \times 15 + 95 \times 4}{2 + 15 + 19 + 15 + 4} = \frac{4240}{56} = 75.71(\text{分})$$

(3) 调和平均数

• 也称倒数平均数

——变量值的倒数的算术平均数的倒数。

加权调和平均数的计算公式 (m =权数)：

$$\bar{x}_H = \frac{1}{\frac{\frac{m_1}{x_1} + \frac{m_2}{x_2} + \cdots + \frac{m_n}{x_n}}{m_1 + m_2 + \cdots + m_n}} = \frac{m_1 + m_2 + \cdots + m_n}{\frac{m_1}{x_1} + \frac{m_2}{x_2} + \cdots + \frac{m_n}{x_n}} = \frac{\sum m}{\sum \frac{m}{x}}$$

调和平均数通常作为加权算术平均数的变形公式使用

- 当缺乏分子数据时，采用算术平均数；
- 当缺乏分母数据时，采用调和平均数。

$$\bar{x} = \frac{\sum xf}{\sum f} = \frac{\sum (xf)}{\sum \frac{1}{x}(xf)}$$

$$\bar{x} = \frac{\sum m}{\sum \frac{1}{x}m}$$

【例3-1+】 若表 3-1的工人数未知而已知各组总产量计算工人平均日产量。

某企业某日工人日产量

日产量/件 x	日总产量/件 xf
10	700
11	1 100
12	4 560
13	1 950
14	1 400
合计	9 710

$$\begin{aligned}\bar{x} &= \frac{\sum xf}{\sum \frac{xf}{x}} \\&= \frac{700 + 1\,100 + 4\,560 + 1\,950 + 1\,400}{\frac{700}{10} + \frac{1\,100}{11} + \frac{4\,560}{12} + \frac{1\,950}{13} + \frac{1\,400}{14}} \\&= \frac{9\,710}{800} = 12.1375 (\text{件})\end{aligned}$$

例 (3-3*)

某供销社分三批收购某种农副产品，其收购单价及各批收购额如下：

批次	单价 (元) x	收购额 xf
1	2.40	6000
2	2.25	12000
3	2.15	2150
合计	——	20150

解：

$$\begin{aligned}x &= \frac{\text{收购额}}{\text{收购量}} = \frac{\sum xf}{\sum f} = \frac{\sum xf}{\sum \frac{1}{x} xf} \\&= \frac{6000 + 12000 + 2150}{6000/2.40 + 12000/2.25 + 2150/2.15} \\&= \frac{20150}{2500 + 5333.33 + 1000} \\&= \frac{20150}{8833.33} = 2.28\end{aligned}$$

【附】对相对数求总平均

【例】某公司下属18个企业的计划完成情况如下表，试求它们的平均计划完成百分比：

产值计划完成程度(%)	组中值 (%) x	企业数 (个) f ?	计划产值 (万元)	实际产值 (万元)
80—90	85	2	800	680
90—100	95	3	2500	2375
100—110	105	10	17200	18060
110—120	115	3	4400	5060
合 计	——	18	24900	26175

平均计划完成百分比——解

$$\text{平均产值计划完成程度} = \frac{\text{实际总产值}}{\text{计划总产值}}$$

如果已知各组的产值计划完成程度和计划产值，则应采用加权算术平均（以计划产值为权数）

$$\bar{x} = \frac{\sum xf}{\sum f} = \frac{0.85 \times 800 + 0.95 \times 2500 + 1.05 \times 17200 + 1.15 \times 4400}{800 + 2500 + 17200 + 4400}$$

如果已知各组的产值计划完成程度和实际产值，则采用加权调和平均（以实际产值为权数m）

$$\text{平均产值计划完成程度} = \frac{\sum xf}{\sum \frac{1}{x}xf} = \frac{26\ 175}{24\ 900} \approx 105.12\%$$

小结

- (1) 选择加权算术平均法还是调和平均法，应该根据基本公式和已知资料而定。
- (2) 计算相对数的算术平均数必须符合相对数本身公式
 - 各组相对数的平均=总体的相对数
 - 将分子视为总体标志总量，分母视为总体单位总量

(4) 算术平均数的特点和数学性质

特点:

- 算术平均数受极端变量值的影响
 - 实际工作中为了尽可能避免极端值影响，常常计算**切尾平均数**——去掉数据大小两端的若干数值后计算中间数据的平均数。

(4) 算术平均数的数学性质(1)

① 算术平均数与变量值个数的乘积等于标志总量（所有变量值的总和）

$$\bar{x} n = \sum_{i=1}^n x_i$$

$$\bar{x} \Sigma f = \sum_{i=1}^n x_i f_i$$

这说明：可以利用算术平均数推算相应的标志总量。

(4) 算术平均数的数学性质(2)

- ②变量值与算术平均数的离差和为零

$$\sum(x - \bar{x}) = 0 \quad \sum(x - \bar{x})f = 0$$

这说明:算术平均数实际上使得变量值的正负离差相互抵消, 从而把总体各单位变量值的差异抽象掉了, 所以它是一组数据的重心, 可以代表一般水平。

(4) 算术平均数的数学性质(3)

③变量值与算术平均数的离差平方和最小

$$\Sigma(x - \bar{x})^2 \leq \Sigma(x - c)^2$$

$$\Sigma(x - \bar{x})^2 f \leq \Sigma(x - c)^2 f$$

这说明：平均数是集中趋势最好的代表值，若以算术平均数以外的任何数为中心，其离差平方和都更大

2. 几何平均数

$$\bar{X} = \sqrt[n]{X_1 \cdot X_2 \cdots X_n}$$

几何平均数通常用在总量等于各分量乘积的情形（各个数据的乘积有意义且变量值中不存在0或负数）。

- 比如，求平均发展速度、某些平均比率等。

例

如某流水生产线有前后衔接的五道工序，某日各工序产品的合格率分别为**97%**、**96%**、**98%**、**98.5%**、**99%**，整个流水生产线产品的**平均合格率**为：

$$\begin{aligned}\bar{x}_G &= \sqrt[5]{0.97 \times 0.96 \times 0.98 \times 0.985 \times 0.99} \\ &= \sqrt[5]{0.8899} = 0.9769 = 97.69\%\end{aligned}$$

思考：平均废品率为多少？

例：某流水生产线有前后衔接的五道工序。某日各工序产品的废品率分别为3%、4%、2%、1.5%、1%，整个流水线上产品的平均废品率？

$$\begin{aligned}\text{平均废品率} &= 1 - \text{平均合格率} \\ &= 1 - 97.69\% = 2.31\%\end{aligned}$$

【思考】 一位投资者持有一种股票，近四年的年收益率分别为4.5%、2.0%、3.5%、5.4%。计算该投资者在这四年内的年平均收益率。

加权几何平均法

$$\bar{x} = \sqrt[\Sigma f]{x_1^{f_1} \times x_2^{f_2} \times \dots \times x_n^{f_n}}$$

【例】某金融机构以复利方式计息。近**12**年来的年利率有**4**年为**3%**、**2**年为**5%**、**2**年为**8%**、**3**年为**10%**、**1**年为**15%**。则**12**年的平均年利率？

$$\begin{aligned}\bar{x} &= \sqrt{(4+2+2+3+1)}{1.03^4 \times 1.05^2 \times 1.08^2 \times 1.10^3 \times 1.15} \\ &= 106.82\%\end{aligned}$$

平均年利率=106.82% - 100%=6.82%

3.3.2 位置平均数

1. 众数

2. 中位数

(3. 分位数)

1. 众数 (Mode)

概念：众数是指总体中出现次数最多或频率最大的变量值（数据），用 M_o 表示。

例如

由未分组数据或单变量值分组的数列确定众数时，直接找出创新次数最多的变量值即可

例：由品质数列确定众数



文化程度	人数 (人)	比重 (%)
小学	400	8
初中	1500	30
高中	2600	52
大学	500	10
合计	5000	100

频数最多或频率(52%)最大的组是“高中”，因此，

$M_0 = \text{“高中”}$

由等距数列近似计算众数

- 先确定众数所在组——次数最多的组。
- 再根据众数组与相邻两组的次数差来近似推算，如图：



例

按成绩分 组（分）	学生人数 （人）
60以下	2
60—70	15
70—80	20
80—90	15
90—100	4
合计	56

下限公式: $M_0 = L + \frac{\Delta_1}{\Delta_1 + \Delta_2} \times d$

$$M_0 = 70 + \frac{19 - 15}{(19 - 15) + (19 - 15)} \times 10 = 75(\text{分})$$

上限公式: $M_0 = U - \frac{\Delta_2}{\Delta_1 + \Delta_2} \times d$

$$M_0 = 80 - \frac{19 - 15}{(19 - 15) + (19 - 15)} \times 10 = 75(\text{分})$$


企业职工按月生产量分组

月产量 (件)	职工人数 (人)
500 以下	208
500-600	314
600-700	382
700-800	456
800-900	305
900-1000	237
1000-1100	78
1100以上	20
合计	2000

$$M_0 = 700 + \frac{74}{74+151} \times 100$$
$$= 732.89 \text{ (件)}$$

众数的特性:

- 众数适用于所有量化层次的数据;
- 众数是一种位置平均数, 不受极端变量值的影响;
- 众数可能不存在 (有前提);
- 众数不一定是唯一的 (可能存在多个众数)。




计算和应用众数的前提条件


- 总体单位多

- 数据： 8 7 9 8 7 7 ——众数=7 ?


- 分布有明显的集中趋势



不存在
众数



存在一个
众数



存在两个众数
(双峰分布)


收入的中位数

2023年全国居民人均可支配收入**39218**元，比上年增长**6.3%**，扣除价格因素，实际增长**6.1%**。全国居民**人均可支配收入中位数33036**元，增长**5.3%**。

按常住地分，**城镇**居民人均可支配收入**51821**元，比上年增长**5.1%**，扣除价格因素，实际增长**4.8%**。**城镇居民**人均可支配收入中位数**47122**元，增长**4.4%**。**农村**居民人均可支配收入**21691**元，比上年增长**7.7%**，扣除价格因素，实际增长**7.6%**。**农村居民**人均可支配收入中位数**18748**元，增长**5.7%**。

2. 中位数 (Median)

- 概念：中位数是将变量值按大小顺序排序，处于中间位置的变量值（或数据）即中位数，用 **Me** 表示。



中位数的确定

未分组数据:

$$\text{中位数位置} = \frac{N+1}{2}$$

$$M_e = \begin{cases} X_{\left(\frac{N+1}{2}\right)} & \text{当 } N \text{ 为奇数时} \\ \frac{1}{2} \left(X_{\frac{N}{2}} + X_{\frac{N}{2}+1} \right) & \text{当 } N \text{ 为偶数时} \end{cases}$$

例

原始数据:	84	82	81	86	80
排 序:	80	81	82	84	86
位 置:	1	2	3	4	5

$$\text{中位数位置} = \frac{n+1}{2} = \frac{5+1}{2} = 3$$

中位数 **Me = 82**

例

原始数据: **84 82 81 86 80 90**

排 序: **80 81 82 84 86 90**

位 置: **1 2 3 4 5 6**

$$\text{中位数位置} = \frac{n+1}{2} = \frac{6+1}{2} = 3.5$$

$$\text{中位数 } Me = 83$$

特性: 中位数是位置代表值, 不受极端值的影响; 具有较高的稳健性; 可用于定序数据和定量数据。

由单项数列确定中位数时，需先做次数累计（向上或向下），中间位置所在组的变量值即是。如：

文化程度	人数 (人)	比重 (%)	向上 累计%
小学	400	8	8
初中	1500	30	38
高中	2600	52	90
大学	500	10	100
合计	5000	100	—

中位数的位置
为 50%，

从累计频数
看，中位数应在
“高中”这一组
别中。因此

$$M_e = \text{“高中”}$$

在组距数列中确定中位数

- 计算向上（下）累计次数；
- 确定中位数的位置 $k=N/2$ 及其所在组；
- 用公式确定中位数：

（下限公式）

$$m_e = L + \frac{\Sigma f / 2 - S_{m-1}}{f_m} \times d$$

该公式假定中位数组的频数在该组内均匀分布

其中：

L 为中位数组的下限；


Σf 为总次数；

S_{m-1} 为中位数组前一组的向上累计次数；

f_m 为中位数组的次数；

d 为中位数组的组距。

图示——证



假定中位数组的频数均匀分布，则频数密度一致：

$$\frac{f_m}{U - L} = \frac{\Sigma f / 2 - S_{m-1}}{M_e - L}$$

整理得中位数的计算公式（下限公式），上限公式同理（略）

例


按成绩分 组（分）	学生人数 （人）
60以下	2
60—70	15
70—80	20
80—90	15
90—100	4
合 计	56

$$m_e = L + \frac{\Sigma f / 2 - S_{m-1}}{f_m} \times d$$
$$= 70 + \frac{28 - 17}{20} \times 10 = 75.50(\text{分})$$

3. 四分位数 (Quartile)

与中位数类似的还有四分位数、十分位数和百分位数等，统称为**分位数**。

- **四分位数**是将全部数据等分为**4**部分的**3**个点的变量值，其中每部分包括**25%**的数据。
- 第2个四分位数 (Q_2) 就是中位数，通常所说的四分位数是指处在**25%**位置上的数值 (第1四分位数 Q_1 , 下四分位数 Q_L) 和处在**75%**位置上的数值 (第3四分位数 Q_3 , 上四分位数 Q_U) 。



【例】

假设**10**名学生的成绩分别为：

50、65、73、77、78、80、85、85、88、92

试计算成绩的四分位数。

$$Q_L \text{ 的位置} = \frac{n+1}{4} = \frac{10+1}{4} = 2.75 \quad Q_U \text{ 的位置} = \frac{3(n+1)}{4} = \frac{3(10+1)}{4} = 8.25$$

$$Q_L = 65 + (73 - 65) \times 0.75 = 71 \text{ (分)}$$

$$Q_U = 85 + (88 - 85) \times 0.25 = 85.75 \text{ (分)}$$

问题——此例存在什么问题？

(见备注)

【十分位数和百分位数】

十分位数是使用**9**个点将全部数据**10**等分后各分位点上的值。

百分位数是使用**99**个点将全部数据**100**等分后各分位点上的值。

例如：收入按高低分为**7**组：

- 最低—较低—中等偏下—中等—中等偏上—较高—最高
10% —10% —20%——20%——20%——10%—10%

（其中5%困难）

工资指导价的高位数、低位数？

分职业中类企业从业人员工资价位（2020年）

单位：万元/年


——人力资源
与社会保障部

职业中类名称	分 位 值				
	10%	25%	50%	75%	90%
企事业单位负责人	3.84	5.30	8.20	14.55	26.19
工程技术人员	3.57	4.58	6.53	10.18	15.94
农业技术人员	2.38	3.07	4.25	6.00	9.23
卫生专业技术人员	2.88	3.69	5.35	7.87	12.00
经济和金融专业人员	3.57	4.56	6.60	10.76	17.42
教学人员*	2.42	3.20	4.49	7.08	10.41
文学艺术、体育专业人员	3.02	4.05	5.55	8.83	13.82
新闻出版、文化专业人员	3.43	4.47	6.24	9.77	15.59
其他专业技术人员	3.58	4.74	6.80	10.09	15.64
办事人员	3.12	3.98	5.58	8.39	13.07
安全和消防人员	2.64	3.37	4.36	6.03	8.48
其他办事人员和有关人员	3.24	4.20	6.00	8.92	13.72
批发与零售服务人员	2.71	3.48	4.64	6.80	10.31
交通运输、仓储和邮政业服务人员	3.00	3.91	5.32	7.37	10.13
住宿和餐饮服务人员	2.52	3.15	4.08	5.47	7.41

众数、中位数和均值的关系

中位数、众数和平均数之间的数量关系取决于总体的次数分配状况。


对称钟型分布



均值 = 中位数 = 众数


$$x = m_e = m_o$$

左偏分布



$$x < m_e < m_o$$

右偏分布



$$m_o < m_e < \bar{x}$$

【附】经验公式

在偏斜适度（微偏）的情况下，不论左偏还是右偏，则有如下的经验公式：

$$(\bar{x} - m_o) \approx 3(\bar{x} - m_e)$$

3.2.3 计算和应用平均指标应注意的问题

- 同质性——应用平均指标的基本原则
- 与分组结合
- 与变异指标结合

一则笑话

- 如果你一只脚放在摄氏 **1** 度的水里，另一只脚放在摄氏 **79** 度的水里，平均水温 **40** 度，你一定感觉很舒服？
- 显然，只了解变量的集中趋势是不够的！



投资的统计思考

下面是美国1950—1999年50年三种投资获利的数据


• 投资	平均获利	标准差
• 短期国库券	5.34%	2.96%
• 长期国库券	6.12%	10.73%
• 股票	14.62%	16.32%

投资的获利和风险常用平均数和标准差来描述。

一般而言，获利较高的风险也较大！


次数分布的两种主要特征

集中趋势
(分布中心)



离中趋势 (变异程度)

——数据偏离其分布中心的程度



3.3 统计数据离中趋势的描述——变异指标

3.3.1 变异指标测定的必要性

3.3.2 极差与四分位差

3.3.3 平均差

3.3.4 标准差和方差

3.3.5 离散系数与异众比率

3.2.1 变异指标的概念和作用

变异指标——反映统计数据差异程度的综合指标，又称标志变动度。

- 测定数据差异程度（或离散程度、均衡性、稳定性）
- 衡量集中趋势测度值（平均数）的代表性大小。
 - 变异指标越大，平均数代表性越小；
 - 变异指标越小，平均数代表性越大。

【例】

某车间有两个生产小组，某周5天的产量如下：

甲：171，172，172，172，173（件）

乙：220，190，170，150，130（件）

- 两组的平均日产量均为172件。
- 平均日产量172件的代表性甲组比乙组好。

3.3.2 极差与四分位差

1. 极差(全距Range):

$R = \text{最大值} - \text{最小值}$


对组距数列:

$R \approx \text{最大组的上限} - \text{最小组的下限}$

极差的优点和局限性

- 简单, 明确;
- 易受极端值影响, 不能反映中间变量值的差异, 不能充分反映数据的分布

极差（全距）是数据离势的不敏感量度



全距信息含量不大，全距只是量化了数据集中最大最小两个极端值之间距离，反映不出所有测量值对于中心的离散程度。但由于计算简便，常用来检查产品质量的稳定性和进行质量控制，如极差控制图。

3.3.2 极差与四分位差（续）

2. 四分位差（也称为内距或四分间距）

——上四分位数与下四分位数之差，用 Q_D 表示：

$$Q_D = Q_U - Q_L$$

- 四分位差反映了中间50%数据的离散程度
 - 其数值越小，说明中间数据越集中，一定程度上也说明了中位数对一组数据的代表程度。
- 不受极值的影响。

3.3.3 平均差

平均差 (Average Deviation)

——变量值与平均数的离差绝对值的平均数

$$A.D = \frac{\sum |x - \bar{x}|}{n}$$

(未分组时)

$$A.D = \frac{\sum |x - \bar{x}| f}{\sum f}$$

(分组时)

平均差的优点和局限性

- 能够充分反映变量值的离差大小;含义清晰
- 取绝对值计算, 数学性质较差, 应用有一定局限, 实践中不及用方差和标准差更常用。

例

成绩 (分)	组中值 x	学生人数 f	离差绝对值 $ x - \bar{x} $	离差绝对值之和 $ x - \bar{x} f$
60以下	55	2	20.71	41.42
60—70	65	15	10.71	160.65
70—80	75	20	0.71	13.49
80—90	85	15	9.29	139.35
90—100	95	4	19.29	77.16
合计	——	56	——	432.07

【均值 = 75.71】

$$A.D = \frac{\sum |x - \bar{x}|f}{\sum f} = \frac{432.07}{56} = 7.72(\text{分})$$

平均说来该班每个学生的成绩与平均成绩相差**7.72**分

3.3.4 方差和标准差

——测度标志变异最重要，最常用的指标。

方差 (Variance) σ^2

——变量值与平均数的离差平方的平均数。

标准差 (Standard Deviation, 又称均方根差), σ

=方差的平方根。

$$\sigma^2 = \frac{\sum (x - \bar{x})^2}{n}$$

(未分组时)

$$\sigma^2 = \frac{\sum (x - \bar{x})^2 f}{\sum f}$$

(分组时)

成绩 (分)	学生人数	$x - \bar{x}$	$(x - \bar{x})^2 f$
55	2	-20.71	857.808
65	15	-10.71	1720.562
75	20	-0.71	9.578
85	15	9.29	1294.562
95	4	19.29	1488.416
合计	56	——	5370.926

平均成绩 = 75.71 (分)

$$\sigma^2 = \frac{\sum (x - \bar{x})^2 f}{\sum f} = \frac{5370.926}{56} = 95.91$$

$$\sigma = \sqrt{\frac{\sum (x - \bar{x})^2 f}{\sum f}} = \sqrt{\frac{5370.926}{56}} = 9.79 \text{ (分)}$$

方差和标准差的数学性质

(1) 若每一个变量值加上一个常数，方差和标准差不变。设 a 为任意常数，

$y_i = x_i + a$ ，则有

$$\sigma_y^2 = \sigma_x^2 \quad \sigma_y = \sigma_x$$

方差和标准差的数学性质（续）

(2) 若每一个变量值均扩大一个常数倍，方差和标准差也同比例变化。设 a 为任意常数， $y_i = ax_i$ ，则有

$$\sigma_y^2 = a^2 \sigma_x^2 \quad \sigma_y = |a| \sigma_x$$

方差的主要数学性质（续）

(3) 分组条件下,

● 总方差 = 各组方差平均数 + 组间方差

$$\sigma^2 = \overline{\sigma^2} + \sigma_B^2$$

● 各组方差平均数

$$\overline{\sigma^2} = \frac{\sum_{i=1}^n \sigma_i^2 f_i}{\sum_{i=1}^n f_i}$$

● 组间方差

$$\sigma_B^2 = \frac{\sum_{i=1}^n (\bar{x}_i - \bar{x})^2 f_i}{\sum_{i=1}^n f_i}$$

3.3.5 离散系数与异众比率

1. 离散系数（也称变异系数）

（例1）

	算术平均数	标准差
身高 /cm	172	6
体重/kg	60	4

- 身高与体重，哪个差异大？

(例2)

- 比较某地一群父亲与新生儿的体重差异：
 - 父亲们的平均体重是**70kg**，标准差是**7kg**
 - 新生儿的平均体重是**3.2kg**，标准差是**0.4kg**
- 能否认为新生儿体重的差异小于父亲们的体重差异？
- 为什么？

应用全距、平均差、方差和标准差时必须注意：

- 它们都是有计量单位的指标；指标的大小受变量值水平的高低。
- 不能直接用于比较不同水平或不同量纲的数列之间的差异程度

此时，须计算**离散系数**——**标志变异指标与其均值之比**，消除了数据水平高低和计量单位的影响，测度数据的相对离散程度。

离散系数包括：

全距（极差）系数 $V_R = \frac{R}{\bar{x}}$

平均差系数 $V_{AD} = \frac{AD}{\bar{x}}$

标准差系数 $V_{\sigma} = \frac{\sigma}{\bar{x}}$

最常用的变异系数是标准差系数。

例1——解答

指标	算术平均数	标准差	标准差系数
身高	172	6	0.035
体重	60	4	0.067

体重的差异程度较大。

平均身高的代表性好于平均体重。

2. 异众比率

1. 离散程度的测度值之一
2. 非众数组的频数占总频数的比重
3. 计算公式为：

$$V_r = \frac{\sum F_i - F_m}{\sum F_i} = 1 - \frac{F_m}{\sum F_i} = 1 - \frac{\text{众数组次数}}{\text{总次数}}$$

4. 用于衡量众数的代表程度，主要适用于定类数据。

例

某专业学生选修二外的频数分布

语种	人数(人)	频率(%)
德语	52	26
法语	94	47
西班牙语	14	7
日语	28	14
阿拉伯语	10	5
其他	2	1
合计	200	100

$$\begin{aligned}V_r &= \frac{200 - 94}{200} \\&= 1 - 0.47 \\&= 0.53 = 53\%\end{aligned}$$

这说明在所调查的200人当中，选修法语的学生人数占47%，异众比率还是比较大。因此，用“法语”来代表学生选修二外的集中趋势，其代表性不是很高。

3.4 数据分布形态的测定—— 偏度和峰度

- 偏态（偏度 *Skewness*）是指频数分布曲线的非对称的方向和程度，
- 峰态（峰度 *Kurtosis*）是指频数分布曲线的尖峭程度。

偏态和峰态主要用于判断总体的分布是否接近于正态分布。

3.4.1 矩（动差）

矩（动差）——一系列刻画数据分布特征的指标的统称。

- 变量值与数值 a 之离差的 K 次方的平均数称为变量 x 关于 a 的 K 阶矩，即：

$$\frac{\sum (x - a)^k}{n}$$

（未分组时）

$$\frac{\sum_{i=1}^n (x_i - a)^k f_i}{\sum_{i=1}^n f_i}$$

（分组时）

● **K 阶原点矩** (当 $a = 0$ 时) 是数据的 K 次方的平均数.

- 一阶原点矩即算术平均数;
- 二阶原点矩即平方平均数。


● **K 阶中心矩** (当 $a = \text{均值}$ 时) 是以均值为中心计算的离差 K 次方的平均数

- $k=1$ 时, 称为一阶中心矩, 它恒等于0, 即 $m_1=0$;
- $k=2$ 时, 称为二阶中心矩, 也就是方差, 即 $m_2=\sigma^2$ 。


3.4.2 偏态的测定

偏度——指数据分布的不对称程度或偏斜程度。

- 以 对称分布 为标准来区分
- 偏态分布又分左偏（负偏）和右偏（正偏）。



左偏分布
(负偏)




右偏分布
(正偏)

偏度(偏度系数)

测定偏度最常用的方法——利用 **3** 阶中心矩 m_3 来计算偏度系数

- 原理：若分布不对称，则 **3** 阶中心矩不为**0**。不对此程度愈严重， **3** 阶中心矩的绝对值愈大。为消除量纲的影响，可除以 σ^3 。

$$Skew = \frac{m_3}{\sigma^3}$$



【附】测度偏态的其他方法

1. 由均值与众数（中位数）之间的关系求偏态系数：


$$S_k = \frac{\bar{x} - M_o}{\sigma} \approx \frac{3(\bar{x} - Me)}{\sigma}$$

一般有：

极左偏态

对称分布


极右偏态



2. 由3个四分位数之间的关系求偏态系数

$$S_k = \frac{Q_3 + Q_1 - 2M_e}{Q_3 - Q_1}$$

值域： $-1 \leq S_k \leq 1$




3.4.3 峰态 (*Kurtosis*)

峰度——是指变量的集中程度和分布曲线的陡峭（或平坦）的程度。

- 对峰度的度量通常以正态分布曲线为比较标准，分为正态峰度、尖顶峰度和平顶峰度。

- 尖顶峰度的分布曲线比正态分布曲线更加尖峭、更高更窄；
- 平顶峰度的分布曲线比正态分配曲线更为平缓、更低更扁平。



尖峰分布



平顶分布

峰度系数

原理：分布曲线的尖峭程度与偶数阶中心矩的数值大小有直接关系。以四阶中心矩 m_4 为基础，为了消除量纲的影响，再除以标准差的四次方 σ^4 所得到的相对数即可衡量峰度。

- 对于正态分布曲线有：
 $m_4 / \sigma^4 = 3$ ，故峰度系数为：

$$Kurt = \frac{m_4}{\sigma^4} - 3$$

- 当**Kurt=0**时，分布曲线为正态曲线；
- 当**Kurt>0**时，为尖顶曲线，表示数据比正态分布更集中在均值附近；数值越大，则变量分布曲线之顶端越尖峭；
- 当**Kurt<0**时，为平顶曲线，表示数据比正态分布更分散；**Kurt**的数值越小，则变量分布曲线之顶端越平坦。

【例】计算平均差和方差、标准差

使用寿命 (小时)	组中值 (x)	试验数量 (只) f	频率 ($f/\Sigma f$)	$(x-1542)$	$ x-1542 f$	$(x-1542)^2*f$
1000以下	900	2	0.020	-642	1284	824328
1000-1200	1100	8	0.080	-442	3536	1562912
1200-1400	1300	16	0.160	-242	3872	937024
1400-1600	1500	35	0.350	-42	1470	61740
1600-1800	1700	23	0.230	158	3634	574172
1800-2000	1900	12	0.120	358	4296	1537968
2000以上	2100	4	0.040	558	2232	1245456
合计	——	100	1.000	——	20324	6743600

$$A.D = \frac{\sum_{i=1}^k |x_i - \bar{x}| f_i}{\sum_{i=1}^k f_i} = \frac{20324}{100} = 203.24$$

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 f_i}{\sum_{i=1}^n f_i} = \frac{6743600}{100} = 67436$$

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2 f_i}{\sum_{i=1}^n f_i}} = \sqrt{\frac{6743600}{100}} = \sqrt{67436} = 259.684$$

【例】

根据前例的数据，计算使用寿命分布的偏度系数和峰度系数。

解：

$$Skew = \frac{m_3}{\sigma^3} = \frac{-113102400 / 100}{(259.6844)^3} = \frac{-1131024}{(259.6844)^3} = -0.0646$$

$$Kurt = \frac{m_4}{\sigma^4} - 3 = \frac{12993157712}{(259.6844)^4} - 3 = -0.1429$$

计算结果表明，偏度系数几乎为**0**，峰度系数略小于**0**，说明该产品使用寿命的分布十分接近对称分布，分布曲线顶峰略比正态分布平坦一些。总的说来，该产品的使用寿命的分布非常接近正态分布。

3.5 Z-分数与相关定理

3.5.1 Z-分数

3.5.2 切比雪夫定理与经验法则

讨论与思考



- 假定某班学生先后两个两次进行了难度不同的综合考试，第一次考试成绩的均值和标准差分别为**80**分和**10**分，而第二次考试成绩的均值和标准差分别为**70**分和**7**分。
- 张三第一、二次考试的成绩分别为**92**分和**80**分，那么在全班相比较而言，他哪一次考试的成绩更好呢？为什么？



3.5.1 Z-分数 (*Z-score*)

● **Z-分数**也称为标准化值或标准得分。

$$Z = \frac{x_i - \bar{x}}{\sigma}$$

● 对于不同性质的变量值或来自不同均值和标准差的个体数据，往往不能直接对比。这就需要将它们转化为同一规格、尺度的数据（标准化值）后再比较。

● 实际上是将不同均值和标准差的总体都转换为均值为**0**、标准差为**1**的总体，将各个体的数据转换为它在其总体中的相对位置。

【例】解答

解：由于两次考试成绩的均值和标准差不同，每个学生两次考试的成绩不宜直接比较。

- 利用标准化值进行对比，表明第二次考试的成绩更好一些。

$$\frac{92 - 80}{10} = 1.20$$

$$\frac{80 - 70}{7} = 1.43$$


3.5.2 切比雪夫定理与经验法则

1.切比雪夫定理——指在任意一个数据集中，位于其平均数左右 m 倍标准差范围之内数据项所占比例至少为 $(1-1/m^2)$ ，其中 m 是大于1的任意实数。

- 至少有3/4（或75%）的数据位于 $(\bar{x} \pm 2\sigma)$ 范围内；
- 至少有8/9（或约89%）的数据位于 $(\bar{x} \pm 3\sigma)$ 范围内；
- 至少有15/16（或约94%）的数据位于 $(\bar{x} \pm 4\sigma)$ 范围内。

切比雪夫定理的优点：适用于任何数据集，对数据分布形态无要求。

正态分布



钟形分布中的经验法则 (empirical rule)

——基于正态分布理论，来确定总体中分布在平均数左右一定范围内的数据项所占的比例：

- 大约有68%的数据项在 $(\bar{x} \pm 1\sigma)$ 范围内；
- 大约有95%的数据项在 $(\bar{x} \pm 2\sigma)$ 范围内；
- 大约有99.7%的数据项在 $(\bar{x} \pm 3\sigma)$ 范围内。

钟形分布中的经验法则（续）

- 经验法则也可以用于判断数据分布是否近似正态分布；
- 经验法则还可以用于识别异常数据：
 - 如通常将落在区间 $[x-3\sigma, x+3\sigma]$ 之外的数据称为异常数据（离群点）。

3.6 箱线图 (Boxplot)

一般说来，当数据分布接近于对称分布时，我们可以用平均数和标准差简要反映数据的特征。但当数据分布呈明显偏态时，可用最小值、下四分位数、中位数、上四分位数与最大值——“五数综合”进行描述。

用箱线图（也译为箱形图、盒式图、盒须图）表示更直观，而且还能识别数据中的异常值。

箱线图常用于质量管理、人事测评、探索性数据分析等统计分析中。

绘制箱线图的步骤

- (1) 计算出数据的五个特征值：最小值， Q_1 ， Me ， Q_3 ，最大值；
- (2) 以 Q_1 为底、 Q_3 为顶绘制一个矩形箱体；在箱体内用一条线代表 Me （也可横向绘制，此略）；
- (3) 箱体上、下的两条竖线分别称为“上须”、“下须”。其上、下端的横线就是上、下边缘（上界、下界）。

上须、下须的长度不大于箱体长度（四分位差 Q_D ）的1.5倍，即：


- 若 $\text{最大值} - Q_3 \leq 1.5Q_D$ ，上边缘 = 最大值；
- 若 $\text{最大值} - Q_3 > 1.5Q_D$ ，上边缘 = $Q_3 + 1.5Q_D$

同理，若 $\text{最小值} - Q_1 \leq 1.5Q_D$ ，下边缘 = 最小值；

若 $\text{最小值} - Q_1 > 1.5Q_D$ ，下边缘 = $Q_1 - 1.5Q_D$ 。

- (4) **离群点**（超越上、下界的变量值）在箱体的上、下方用小圆圈表示。

图3.6 箱线图




SPSS等软件可绘制箱线图——见二维码/学习通资料。

箱线图的解读

- 数据分布的集中趋势、一般水平—— Me ；
- 数据分布的离散程度——箱体长度（四分位距 Q_D ）、须长、最大（小）值；
- 数据分布的形态（偏态）——箱体中 Me 上下箱体长度是否对称（若下方箱体较长即 Me 偏上边缘，说明数据呈负偏，反之呈正偏），还可以结合上下须长度来观察。
- 判别数据中的异常值——箱线图中异常值被定义为小于 $(Q_1 - 1.5Q_D)$ 或大于 $(Q_3 + 1.5Q_D)$ 的值，用小圆圈表示。
- 多组数据的箱线图可并行排列，便于直观比较几组数据的分布信息，如下图：

【例】多组数据的箱线图

4个科目考试成绩的箱线图：



本章小结

- 总量指标的概念和种类、计量单位；
- 相对指标的概念、种类与计算；
- 测度集中趋势的各种指标的含义、计算方法、特点和应用场合
- 测度离散程度的各种指标的含义、计算方法、特点和应用场合
- 偏度与峰度的含义和基本测度方法
- **Z**分数、经验法则、箱线图
- 利用 **Excel** 或其它软件计算常用统计指标

【思考与练习】 选择哪个品种？



- 假设某种农作物有两个品种，它们的平均亩产及其标准差分别为：

品种	平均亩产	标准差(单位: kg/亩)
A	300	10
B	320	20

- 你认为哪个品种较优？为什么？

【附】样本的偏度与峰度

不对称度的计算公式定义如下：

$$\frac{n}{(n-1)(n-2)} \sum \left(\frac{x_j - \bar{x}}{s} \right)^3$$

峰值的计算公式如下：

$$\left\{ \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum \left(\frac{x_j - \bar{x}}{s} \right)^4 \right\} - \frac{3(n-1)^2}{(n-2)(n-3)}$$

S 为样本的标准偏差。

【补充】证明：
算术平均数 > 几何平均数

$$(a-b)^2 > 0, \quad a^2 + b^2 - 2ab > 0,$$
$$a^2 + b^2 + 2ab > 4ab,$$

$$(a+b)^2 > 4ab, \quad \left(\frac{a+b}{2}\right)^2 > ab,$$

$$\left(\frac{a+b}{2}\right) > \sqrt{ab} \quad (a, b > 0, a \neq b)$$

数值平均的通式（幂平均函数）

$$\sqrt[K]{\frac{a^K + b^K}{2}}$$

$$\left(\frac{\sum x_i^K w_i}{\sum w_i} \right)^{\frac{1}{K}}$$

- 当 $K=1$, 上式=算术平均数;
- 当 $K=-1$, 上式=调和平均数;
- 当 $K \rightarrow 0$, 上式=几何平均数
- 当 $K=2$, 上式=平方平均数;
- 当 $K=\infty$, 上式=最大值;
- 当 $K=-\infty$, 上式=最小值;
- K 越大, 上式越大, 反之则反