

统计学基础

统计学基础知识点

总论、统计数据的收集整理与描述、数据特征的描述

总论

认识统计学的对象、语言和数据类型。

数据描述

理解数据怎样收集、整理、制表和制图。

数据特征

从集中、离散和形状三个角度概括数据。

课程结构

一条完整的数据分析链



第一章 总论

建立统计学的基本概念框架。

第二章 收集、整理与描述

把零散数据变成可阅读的信息。

第三章 数据特征描述

用指标概括数据的中心、差异与形状。

总论：先学会统计学的基本语言

总论

统计的含义

统计工作、统计资料、统计学

统计学类型

描述统计、推断统计

基本概念

总体、个体、样本、参数、统计量

标志、指标与变量

个体特征、总体特征、可变特征

统计数据类型

定性、定量、计量尺度、时间状态

统计学的基本认识

统计学是用数据认识现象的方法

概念	核心含义	例子
统计工作	收集、整理、分析数据的活动	调查学生消费、整理企业销售额
统计资料	统计工作得到的数据材料	调查表、统计报表、数据表
统计学	研究数据方法的学科	如何抽样、如何制表、如何分析

统计学研究的不是孤立数字，而是大量现象背后的数量规律。

统计学类型

描述统计看样子，推断统计看总体

描述统计

回答“数据本身是什么样”。常见工作包括整理数据、画图、计算平均数和标准差。

推断统计

回答“总体可能是什么样”。常见工作是用样本信息估计总体参数或进行假设检验。

50 名学生学习时长



画图、求平均



推断全校学生情况

基本概念

从总体到样本，再从样本回到总体

概念	含义	例子：研究某班学生学习情况
总体	研究对象的全体	全班所有学生
个体/总体单位	构成总体的每一个单位	每一名学生
样本	从总体中抽取的一部分个体	抽取的 10 名学生
参数	反映总体特征的指标，通常未知	全班平均成绩
统计量	根据样本计算出的指标	样本平均成绩



标志、指标与变量

个体特征、总体特征和可变特征

概念	说明	例子
标志	说明总体单位特征的名称	性别、成绩、专业
标志值	标志的具体表现	男、85 分
指标	反映总体数量特征	平均成绩、及格率
变量	取值会变化的特征	年龄、收入、满意度

比较	标志	指标
描述对象	个体特征	总体特征
常见阶段	调查阶段	整理和分析阶段
例子	每个学生的成绩	全班平均成绩

统计数据类型

先判断数据类型，再选择整理和展示方法

按能否直接用数字表示

定性数据	类别或属性	性别、专业
定量数据	数量大小	成绩、收入

按变量类型

分类变量	类别，无大小顺序	性别
顺序变量	有等级顺序	满意度
数值型变量	取值是数字	成绩、年龄
离散/连续变量	可数或连续取值	人数、身高

不同尺度能做的比较不同

尺度	能否分类	能否排序	差距有意义	倍数有意义	例子
定类尺度	是	否	否	否	性别、专业
定序尺度	是	是	否	否	满意度等级
定距尺度	是	是	是	否	摄氏温度
定比尺度	是	是	是	是	收入、年龄

截面数据

同一时点上多个对象的数据，如某年各省 GDP。

时间序列数据

同一对象在不同时点的数据，如某企业各月销售额。

统计数据的收集、整理与描述

收集 整理 描述

数据来源

间接来源、直接来源

收集方法

访问法、报告法、直接观察法

统计整理

统计分组、分布数列、频数、频率

调查方案

目的、对象、单位、项目、方法

抽样方法

概率抽样、非概率抽样

数据描述

统计表、统计图

数据来源与调查方案

数据从哪里来，先由研究目的决定

来源	优点	局限
间接来源	成本低、获取快	不一定完全适合研究问题
直接来源	针对性强	成本高、周期长

调查方案项目	要回答的问题
调查目的	为什么调查
调查对象	调查范围是什么
调查单位	具体向谁调查
调查项目	要收集哪些变量
调查方法	如何获得数据

调查单位与要求

调查对象、调查单位、报告单位要分清

概念	含义	例子：调查高校学生月消费
调查对象	调查范围，也就是总体	全校学生
调查单位	具体被调查的单位	每一名学生
报告单位	提交资料的单位	各学院或班级

准确

真实、客观地反映实际情况。

完整

单位和项目不能遗漏。

及时

在需要使用数据前完成收集。

不同问题选择不同收集方式

方法	具体形式	适用场景
访问法	面访、电话调查、电脑辅助调查、座谈会、深访	调查态度、意愿、满意度
报告法	邮寄调查、单位报送、统计报表	组织或单位定期上报数据
直接观察法	观察法、实验法	记录行为、过程或实验结果

怎么看

问卷、访问、访谈。

怎么做

观察法。

是否有影响

实验法。

抽样方法

概率抽样重在可推断，非概率抽样重在方便获取

概率抽样	做法
简单随机抽样	每个单位机会相同
分层抽样	先分层，再在各层抽样
整群抽样	先分群，再抽取若干群
系统抽样	按固定间隔抽取
多阶段抽样	分多个阶段逐步抽取

非概率抽样	风险
方便抽样	代表性较弱
判断抽样	主观性较强
自愿样本	容易偏向积极参与者
滚雪球样本	样本圈层可能集中
配额抽样	不一定随机

统计误差

误差不可怕，关键是知道它从哪里来

类型	含义	是否可避免
登记性误差	填报、记录、录入过程中的错误	可以尽量避免
代表性误差	样本不能完全代表总体造成的误差	抽样调查中常见
系统性误差	调查设计或执行偏差导致的误差	应尽量避免
随机误差	抽样带来的随机波动	不能完全避免，但可以控制

数据不准确，后续整理和分析都会失去意义。

分组让杂乱数据变成结构

1

划分类型

把总体单位分成若干类别。

2

反映结构

观察内部比例关系。

3

揭示关系

发现现象之间的依存关系。

分组原则	含义
科学性	符合研究目的
完备性	每个单位都能归入某一组
互斥性	每个单位只能归入一个组

分组类型	例子
品质标志分组	按性别、专业分组
数量标志分组	按成绩、收入分组
简单/复合分组	按一个或多个标志分组

分布数列、频数与频率

分组之后，要看每组有多少、占多少

概念	含义
组别	分成的各个类别或区间
频数	各组单位数
频率	各组单位数占总体单位数的比重
组距	区间长度
组中值	上限和下限的中点

$$\text{频率} = \text{频数} / \text{总数}$$
$$\text{组距} = \text{上限} - \text{下限}$$
$$\text{组中值} = (\text{上限} + \text{下限}) / 2$$
$$\text{频数密度} = \text{频数} / \text{组距}$$

注意
等距分组可直接比较频数；不等距分组应比较频数密度。

统计表

统计表是整理后数据的规范表达


构成	说明
总标题	说明表格整体内容
横栏标题	说明横向项目
纵列标题	说明纵向项目
横行与纵列	承载数据结构
注释与资料来源	补充说明数据口径

性别	低消费	中消费	高消费	合计
男	18	52	30	100
女	20	57	23	100
合计	38	109	53	200

列联表也叫交叉表，适合观察两个或多个变量之间的分布差异。

不同数据类型，选择不同图形

数据类型	推荐图形
分类数据	条形图、帕累托图、饼图、环形图
顺序数据	累计频数图、累计频率图
分组数值数据	直方图
未分组数值数据	茎叶图、箱线图
时间序列数据	线图
两个变量	散点图



数据特征的描述

数据特征

集中趋势

众数、中位数、平均数、分位数

分布形状

对称分布、右偏分布、左偏分布、峰态

离散趋势

极差、四分位差、方差、标准差、离散系数

箱线图

Q1、中位数、Q3、异常值

数据特征的观察角度

看一组数据，通常看三个问题

中心在哪里

集中趋势：众数、中位数、平均数、分位数。

差异有多大

离散趋势：极差、四分位差、方差、标准差、离散系数。

形状是什么样

分布形状：偏态、峰态、箱线图。

平均数只能说明中心，不能说明所有数据是否接近这个中心。

集中趋势

集中趋势回答“数据中心在哪里”

指标	含义	适用提示
众数	出现次数最多的变量值	分类数据常用
中位数	排序后位于中间位置的数	不易受极端值影响
平均数	全部数值总和除以个数	数值型数据常用
分位数	按位置把数据分成若干部分	常用于描述位置

分类数据

常看众数。

有极端值

中位数更稳健。

数值型数据

平均数最常用。

离散趋势

离散趋势回答“数据之间差异有多大”


指标	含义	特点
极差	最大值 - 最小值	简单，受极端值影响大
四分位差	上四分位数 - 下四分位数	较少受极端值影响
方差	离差平方的平均	常用于理论分析
标准差	方差的平方根	单位与原数据一致
离散系数	标准差 / 平均数	适合跨单位或跨水平比较

对象	平均体重	标准差	离散系数
牛	80 kg	18 kg	22.5%
羊	15 kg	3 kg	20%


平均水平不同的对象，应看离散系数。

分布形状与箱线图


形状告诉我们数据是否对称、是否有异常值



对称分布



右偏分布



左偏分布



快速判断题

用几个小问题收束知识点

问题	参考答案
“很不满意、不满意、一般、满意、很满意” 属于什么变量？	顺序变量
展示班级性别构成，适合什么图？	条形图、饼图或环形图
展示学生成绩分布，适合什么图？	直方图、茎叶图或箱线图
展示企业各月销售额变化，适合什么图？	线图
两个班平均分一样，成绩分布一定一样吗？	不一定，还要看离散程度和分布形状
分组组距不同，能直接比较频数吗？	不能，应比较频数密度